

Analyse et Exploration des données

–
Florent PRADEL




Les bases



Un petit rappel (j'espère) SQL

- ◎ SQL = Structured Query Language
- ◎ Langage de gestion de base de données



Les requêtes de sélection

- La sélection (SELECT) :

SELECT *[nom du champ]* **FROM** *[nom de la table];*

- Les jointures (JOIN):

SELECT [nom du champ] FROM [nom de la table 1]

JOIN *[nom de la table 2]* **ON** *[nom du champ 1] = [nom du champ 2];*

- Les conditions (WHERE):

SELECT [nom du champ] FROM [nom de la table 1]

JOIN [nom de la table 2] ON [nom du champ 1] = [nom du champ 2]

WHERE *[nom du champ 1] = « toto »;*

DML (DATA MANIPULATION LANGUAGE)

- SELECT

SELECT * FROM TABLE
WHERE condition

- INSERT

INSERT INTO table VALUES ('valeur 1', 'valeur 2', ...)

- UPDATE

UPDATE table SET nom_colonne_1 = 'nouvelle valeur'
WHERE condition

- DELETE

DELETE FROM `table`
WHERE condition

Opérateurs de comparaisons

=	Égale
<>	Pas égale
!=	Pas égale
>	Supérieur à
<	Inférieur à
>=	Supérieur ou égale à
<=	Inférieur ou égale à
IN	Liste de plusieurs valeurs possibles
BETWEEN	Valeur comprise dans un intervalle donnée (utile pour les nombres ou dates)
LIKE	Recherche en spécifiant le début, milieu ou fin d'un mot.
IS NULL	Valeur est nulle
IS NOT NULL	Valeur n'est pas nulle

Les fonctions

- SUM() calculer la somme d'un set de résultat
- MAX() obtenir le résultat maximum (fonctionne bien pour un entier)
- MIN() obtenir le résultat minimum
- COUNT() compter le nombre de lignes dans un résultat
- ROUND() arrondir la valeur
- UPPER() afficher une chaîne en majuscule
- LOWER() afficher une chaîne en minuscule
- CONCAT() concaténer des chaînes de caractères
- CURRENT_DATE() date actuelle

Exemple:

```
SELECT SUM(salaire) FROM TABLE_SALAIRE;
```



Group By

- Utilisé avec les fonctions
- Permet de grouper plusieurs résultats
- Exemple :

```
SELECT nom_joueur, id_joueur, SUM(quantité_de_sel)
FROM JOUEUR
JOIN PARTIE_FORTNITE ON id_joueur = id_joueur_fortnite
GROUP BY nom_joueur, id_joueur;
```

Cette requête permet de calculer la somme de sel accumulé par chaque joueur sur toutes les parties de Fortnite.

Le GROUP BY contient tous les champs utilisés dans le SELECT sur lesquels il n'y a pas de fonctions appliquées.



La condition Having

- HAVING = WHERE
- Se place après un GROUP BY
- Exemple :

On veut connaître le **nombre** de transformation que possèdent chaque **personnage** uniquement pour ceux qui en ont **au moins une**.

PERSONNAGE	
Id_personnage	nom_personnage
1	Goku
2	Yamcha
3	Piccolo

TRANSFORMATION	
Id_personnage	transformation
1	Super saiyan
3	Dieu absorbé
1	Kaioken
1	Super saiyan God

Solution

```
SELECT nom_personnage, COUNT(T.transformation)
FROM PERSONNAGE P
JOIN TRANSFORMATION T ON T.id_personnage = p.id_personnage
GROUP BY nom_personnage
HAVING COUNT(T.transformation) > 0;
```

Filtre




nom_personnage	COUNT(T.transformation)
Goku	3
Piccolo	1
Yamcha	0

Les jointures


11

INNER JOIN



```
SELECT *  
FROM A  
INNER JOIN B ON A.key = B.key
```

LEFT JOIN




```
SELECT *  
FROM A  
LEFT JOIN B ON A.key = B.key
```

Les jointures

12


LEFT JOIN (sans l'intersection de B)



— Jointure gauche (LEFT JOIN sans l'intersection B)

```
SELECT *  
FROM A  
LEFT JOIN B ON A.key = B.key  
WHERE B.key IS NULL
```

RIGHT JOIN




— Jointure droite (RIGHT JOIN)

```
SELECT *  
FROM A  
RIGHT JOIN B ON A.key = B.key
```

Les jointures

13


FULL JOIN



— Union de 2 ensembles

```
SELECT *  
FROM A  
FULL JOIN B ON A.key = B.key
```

FULL JOIN (sans intersection)



— Jointure pleine (FULL JOIN sans intersection)

```
SELECT *  
FROM A  
FULL JOIN B ON A.key = B.key  
WHERE A.key IS NULL  
OR B.key IS NULL
```

Les mots clés

14

- EXPLAIN (EXPLAIN PLAN sous Oracle) permet d'afficher le plan d'exécution d'une requête SQL
- **EXPLAIN** SELECT * FROM ma_table;

Résultat #1 (10×7)									
id	select_type	table	type	possible_keys	key	key_len	ref	rows	Extra
1	SIMPLE	CES	ALL	PRIMARY,PAR_NUMERO_COMMANDE_ET_FRS_SOCIETE...	(NULL)	(NULL)	(NULL)	135 792	Using where
1	SIMPLE	CML	eq_ref	PRIMARY	PRIMARY	1	LOCAL.CES.CODE_MODE_LIVRAISON	1	Using where
1	SIMPLE	CSF	eq_ref	PRIMARY	PRIMARY	3	LOCAL.CES.CODE_SUPPORT_FRS	1	Using where
1	SIMPLE	CLS	ref	PRIMARY,PAR_NUMERO_LIGNE_INTERNE_CDF_SOCIET...	PRIMARY	20	LOCAL.CES.CODE_FOURNISSEUR_DE_COMMANDE,LOC...	1	
1	SIMPLE	OPF	eq_ref	PRIMARY	PRIMARY	1	LOCAL.CLS.ORIGINE_PRIX_ACHAT	1	Using where
1	SIMPLE	CP	eq_ref	PRIMARY	PRIMARY	3	LOCAL.CES.CODE_PROPOSITION_FRS	1	Using where
1	SIMPLE	CTC	eq_ref	PRIMARY	PRIMARY	3	LOCAL.CES.CODE_TYPE_COMMANDE_FRS	1	Using where

- Permet de voir si la requête passe bien par les index

Les mots clés

15

- UNION permet de fusionner les résultats de 2 requêtes

```
SELECT nom, age FROM personnes
```

```
UNION
```

```
SELECT nom, age FROM autre_personnes;
```

Les résultats ne forment plus qu'un seul résultat

Les mots clés


16

- MINUS permet de soustraire un résultat d'une requête à un autre

```
SELECT * FROM A
```

```
MINUS
```

```
SELECT * FROM B;
```



Les mots clés

17

- LIMIT permet de limiter le nombre de résultat d'une requête

```
SELECT * FROM comptes_bancaires  
ORDER BY solde_bancaire DESC  
LIMIT 10;
```

Retourne les 10 résultats dont le solde bancaire est le plus élevé

Les index

18

- Permet d'accéder plus rapidement aux données
- Occupe de l'espace dans la BDD
- Ralentit l'insertion de données à cause de la mise à jour de l'index

```
CREATE INDEX `nom_index` ON table (`colonne1`, `colonne2`);
```

Convention de nommage:

Préfixe “PK_” pour Primary Key (traduction : clé primaire)

Préfixe “FK_” pour Foreign Key (traduction : clé étrangère)

Préfixe “UK_” pour Unique Key (traduction : clé unique)

Préfixe “UX_” pour Unique Index (traduction : index unique)

Préfixe “IX_” pour chaque autre Index

DDL (DATA DEFINITION LANGUAGE)

- CREATE
- ALTER
- DROP

-CREATE DATABASE nom_database;

-CREATE TABLE nom_de_la_table

(colonne1 type_donnees,
colonne2 type_donnees,
colonne3 type_donnees,
colonne4 type_donnees);

-DROP TABLE nom_de_la_table;

Transformation de donnée



ETL et ELT

21

- ETL

EXTRACT TRANSFORM LOAD

ETL solution historique, préparation en amont de données finales

- ELT

EXTRACT LOAD TRANSFORM

Solution évolutive plus flexible pour l'analyse



Transformations

22

But des transformations :

- **Epurer** : Ne récupérer que l'essentiel des **colonnes** utiles
- **Filtrer** : Ne récupérer que les **lignes** utiles
- **Agréger** : Générer une nouvelle **table** plus restreinte

Modélisation



Tables de faits et de dimensions

24

- FAIT

Une table de fait contient les mesures et les clés des dimensions

Contiens la grande majorité des données du modèles (80% à 99%)

Ex: Table contenant toutes les commandes (CA, marge, quantité ...)

- DIMENSION

Une table de dimension contient toutes les informations annexes descriptives permettant d'analyser les mesures de la table de fait.

Il y a toujours plus de dimensions que de fait dans un schéma.

Ex : Table contenant toutes les informations client (Nom, adresse ...)

Etoile et Flocon


25

- Etoile

1 table de fait

N tables de dimensions

- Simple et performant




- Flocon

N tables de fait

N tables de dimensions

- Complexe et moins performant



Reporting et BI

L'informatique décisionnelle

27

- La Business intelligence

Est l'utilisation de technologies, applications et processus pour collecter, intégrer, analyser et présenter les données d'une entreprise afin d'aider les utilisateurs à prendre des décisions.

Elle peut inclure des outils de visualisation de données, de reporting, de tableaux de bord et d'analyse de données.



Les outils de stockage de données

28

- Bases de données SQL
- Bases de données NoSQL
- Excel
- Big Data
- ...
- Tout système pouvant contenir une information est une source potentielle d'analyse

Les outils ETL

29

- IBM
- Azure
- Oracle integrator
- Talend
- ...

Ces outils permettent d'agréger des sources de données hétéroclites

La dataViz



La data visualisation

31

La fête du slip



Un outil pour les gouverner tous

32





Power BI

Microsoft

Notre cheminement

Power Bi

Présentation de
l'outil Power Bi

Les données

Importer les données
dans Power Bi

Modéliser

Mise en forme des
jeux de données

Visualiser

Créer des visuels
parlant à partir
des données

Explorer

Création des
rapports et
tableaux de bord

Excel(er)

Liens entre Power
Bi et Excel

Partager

Faire vivre
l'information en la
partageant

Synthèse

Conclusion sur l'outil
Power Bi



Power Bi?

- Ensemble de **logiciels** et **applications**
- Outils d'**analyse de données**
- Outils de **reporting**
- Outils de **prise de décisions** pour les entreprises

**Transformer les données en informations
cohérentes**

Les outils



- **Power Bi Desktop**



Version bureau



- **Power Bi Service**



Version web



- **Power Bi App**




Version mobile et tablette



Les outils

Power Bi Desktop


- ▶ Importation de données
- ▶ Mise en forme de données
- ▶ Création de rapports



Les outils

Power Bi Service

- ▶ Importation de données
- ▶ Création de rapports
- ▶ Création de Dashboard
- ▶ Publication et partage



Les outils

Power Bi App

- Version **mobile** et **tablette**



- **Consultation** des rapports et Dashboard
- **Annotations** possibles





Les données



Le cheminement des données

Importation dans Power Bi Desktop



Publication vers Power Bi Service



Création des **rapports** et **tableaux de bord**
sur Power Bi Service



Partager et **interagir** sur Power Bi
Service et/ou App

Les sources de données

Importation de sources multiples

Fichiers


Excel, Csv, Texte, XML, ...

Bases de données

SQL server, Oracle, MySQL, Access, ...

Services

Google Analytics, Script R, ODBC, Facebook, ...



Modéliser



Modéliser c'est :

- ▶ **Lier les données**

Principe de jointures entre fichiers

- ▶ **Mettre en forme les données**

Ajouter/supprimer des colonnes

Modifier Type

...

- ▶ **Créer des mesures**

Champs calculés sur les données




Lier des fichiers

- Principe de **jointure** (bases de données)
- **Lier** les fichiers par un **attribut commun**
- Power Bi détecte et **créer automatiquement les liaisons** et les **cardinalités**
- **Ne remplace pas** l'expertise humaine

Mise en forme des données

- ▶ **Ajout/Suppression** de colonnes
- ▶ **Modification** du type des colonnes
- ▶ **Actions** enregistrées sous forme de requêtes réutilisables



Les mesures

- **Champs calculés** sur les données
- **Langage DAX** (Data Analysis Expressions)
- **Ex:** Création d'un champs somme des profits



- Ajout d'un **champs exploitable** dans les données





An isometric illustration of a data visualisation dashboard. The scene is set against a blue background with various data visualisation elements. In the center, there are several white server racks on blue bases. To the left, a person stands next to a large screen displaying a pie chart and a list of items. To the right, a person stands next to a large screen displaying a line graph and a list of items. In the foreground, a person sits on a blue block next to a large screen displaying a line graph. The background features floating molecular structures and data points. The overall theme is data analysis and visualisation.

Visualiser



Visualiser les données

- ▶ Permet de **créer des visuels** à partir des données
- ▶ **27 visuels de base**



- Possibilité d'**importer** et/ou de **développer** ses propres **visuels**

2 choix possibles



► **Power Bi Desktop** (client lourd)

- Travail hors connexion
- Possibilité de mettre en forme les données
- Création de rapports



► **Power Bi Service** (client léger)

- Travail en ligne
- Création de rapports



Explorer



Principe général

TABLEAUX DE BORD


CENTRALISATION DES RAPPORTS
DANS UNE VUE D'ENSEMBLE

RAPPORTS

MISE EN FORME DES DONNÉES
SOUS FORME DE TUILES

DONNÉES


CONTIENT LES SOURCES DE DONNÉES
PUBLIER PAR POWER BI DESKTOP





Power Bi Service

- ▶ Application Web
- ▶ Point central de Power Bi
- ▶ Réalisation de **rapports**
- ▶ Réalisation de **tableaux de bord**
- ▶ **Publication**





Quick Insights


- ▶ Créer un **rapport automatique** à partir des données
- ▶ Applicable sur une source de données
- ▶ **Récupération** possible du **rapport** ou de **tuiles**





Questionner les données

- ▶ Barre de **recherche** qui permet de poser une **question en langage Naturel**
(Anglais de préférence actuellement)
- ▶ **Visualisation** des données **pendant la saisie**
- ▶ Possibilité d'enregistrer des questions types
 - « Quel était le chiffre d'affaire de l'année 2015? »
 - « Montre les quantités livrées par ville »





Les widgets (vignettes)


- ▶ Permet d'**ajouter des informations** autres que les sources de données





Les données sont-elles à jour?

- ▶ **Mise à jour** via l'application « Power Bi Personnel Gateway »
- ▶ Permet de **planifier l'actualisation** des données
- ▶ A faire **pour chaque source**







Power Bi et Excel

- ▶ Power Bi **ne remplace pas Excel**
- ▶ Outils **complémentaires**
- ▶ Importation dans Power BI de classeur Excel, Power view, Power Pivot, ...
- ▶ Exportation des sources de données dans Excel
- ▶ **Gestion automatique** des connexions



A top-down view of a group of approximately 15 people of various ages and ethnicities sitting around a large, round white table. The table is covered with a large, colorful graphic of a digital network. At the center of the network is a blue circle containing a white laptop icon. Radiating from this center are numerous lines and nodes, connecting to various other icons. These icons include a red circle with a document icon, a yellow circle with a share icon, a green circle with an envelope icon, a purple circle with a magnifying glass icon, a red circle with a padlock icon, a green circle with a Wi-Fi symbol, a blue circle with a rocket icon, and a yellow circle with a cloud icon. There are also icons for a smartphone, a tablet, a speech bubble, a heart, and a thumbs up. The people are looking at the table, some holding their own devices. The background is a light gray floor.

Partager




Publication et partage

- **Importation** des données dans Power Bi Desktop.
- **Publication** vers Power Bi Service afin de compléter les rapports et créer les tableaux de bord.
- **Partage** vers les utilisateurs Power Bi Service et/ou power Bi App



Publication et partage

- Partage en **lecture seule**(utilisateur/groupe)
- Partage en **groupe administrateur**
- **Impression** des tableaux de bord(papier ou pdf)
- **Annotation** sur version mobile et tablette



Synthèse

3 outils complémentaires

- ▶ **Power Bi Desktop**
Importation de données et création de rapports
- ▶ **Power Bi Service**
Création et consultation de rapports et tableaux de bord
- ▶ **Power Bi App**
Consultation et annotation de rapports et tableaux de bord

- ▶ Outil **complet**
- ▶ **Simple** d'utilisation
- ▶ **Faible** cout
- ▶ Nécessite des **compétences techniques** et **métier**
- ▶ **Power Bi** est un outil de choix pour donner du sens à ses données

Merci pour votre
attention

